

Temporal Graphs for recommendations

Wiktor Małyśa

Mikołaj Orzechowski

Problem i Zadanie Rekomendacji

Problem

Platformy e-commerce obserwują użytkownika w ramach krótkich sesji — serii kliknięć w jednej wizycie. Zanim sesja się skończy, system powinien podpowiedzieć następny produkt.

Zadanie

Next-item prediction: na podstawie dotychczasowych kliknięć w sesji przewidujemy kolejny produkt. Każdy następny klik w logach jest etykietą — nie potrzebujemy ręcznego tagowania danych.

Dlaczego to trudne?

- Sesje są zazwyczaj bardzo krótkie.
- Katalogi produktów są niezwykle liczne.
- Kolejny klik zależy silnie od kontekstu bieżącej sesji, a nie tylko od globalnej popularności przedmiotów.

Statystyki zbioru danych i Przetwarzanie

Kluczowe liczby (pełny train)

Metryka	Wartość
Kliknięcia	33,0 mln
Sesje	9,25 mln
Produkty	52 739
Zakupy	1,15 mln
Wsp. konwersji	5,51%

Jakość i Oczyszczanie danych

- **Brak braków danych:** 0 NaN w clicks, buys i test.
- **Spójność:** Wszystkie sesje z zakupami posiadają kliknięcia.
- **Duplikaty:** Usunięto 69 dokładnych powtórzeń (ID, item, czas).
- **Wyzwanie:** yoochoose-test.dat to nowe sesje (nakładające się daty).

Oś czasu i Podział

- **Okres:** kwiecień–wrzesień 2014 (ms precision).
- **Split chronologiczny:** 70% Train / 15% Val / 15% Test.
- **Brak wycieku:** Podział per cała sesja (wg startu).
- **Metoda:** Sliding window dla treningu (każdy krok).

Charakterystyka Sesji

- **Średnia długość:** ~3,9 klików; 13,6% to 1-klik (wykluczane).
- **Powtarzalność:** ~17% kliknięć to ten sam produkt (A→A).
- **Target:** Tylko ostatni klik w sesji dla Val/Test.
- **Constraint:** min_session_clicks = 2 dla par next-item.

Architektura Preprocessingu Danych

01

Czyszczenie i Parsowanie

- Usuwanie duplikatów (ID, item, czas)
- **Row order:** stabilne sortowanie
- Powtórzenia A→A zostają (EDA: kaskadowość)

02

Subsampling (GPU-ready)

- Frakcja: **0.03125** (1/32 najstarszych)
- Zachowanie pełnych sesji (bez ucinania)
- Ścisłe zachowanie chronologii

03

Podział Train/Val/Test

- Ratio: **70% / 15% / 15%** (po czasie)
- Brak wycieku: cała sesja w jednym splicie
- Granice zapisane w **meta.json**

04

Zarządzanie Słownikiem (Vocab)

- Indeksy budowane **tylko z Train**
- Out-of-Train → **UNK** (osobne dla GRU4Rec/TGN)
- **Padding (PAD):** specyficzny dla sekwencji GRU
- Bucketing kategorii jako cechy krawędzi (TGN)

05

Strumień Zdarzeń (TGN)

- Scalone kliknięcia (+ opcjonalnie zakupy)
- **Cechy:** t_sec, event_type, price_log, quantity
- **Indeksowanie:** session_idx (lokalny), event_id (globalny)
- Domyślnie: **include_buys: false**

06

Przykłady Uczące (Next-Item Prediction)

Split	Metoda Generowania (min. 2 kliknięcia)
Train	Sliding window: każda pozycja od 2. kliku jako przykład
Val/Test	Last click: tylko ostatni klik w sesji jako target

Eksport: GRU4Rec (.parquet), TAGNN (.pickle), TGN (.parquet)

07

Challenge Test


- Pełny zbiór **yoochoose-test**
- **Cold start:** nowe itemy w teście
- Format identyczny z Validation
- Cel: ewaluacja na nieznanym danych

```
data/processed/
├── subsample_1_32_clicks_only/      # GRU4Rec, TAGNN, TGN (same kliknięcia)
│   ├── meta.json
│   ├── vocab/
│   ├── train/  val/  test_internal/
│   │   ├── gru4rec_examples.parquet
│   │   ├── tagnn_examples.pkl
│   │   └── tgn/
│   │       ├── events.parquet
│   │       └── examples.parquet
│   └── challenge_test/              # pełny yoochoose-test.dat (bez subsample)
├── subsample_1_32_with_buys/        # TGN multigraf (kliknięcia + zakupy)
│   ├── meta.json
│   ├── vocab/
│   └── ../tgn/events.parquet       # bez gru4rec/tagnn
```

Nadreprezentacja długich sesji — train split

	% sesji w datasecie	% sekwencji treningowych
Top % długich sesji		
1	1.06	10.28
5	5.78	29.54
10	12.21	44.48
20	23.15	61.22

Nadreprezentacja długich sesji — train split (subsample_1_32_clicks_only)



Kluczowa obserwacja: Sesje o największej liczbie kliknięć dominują w procesie uczenia. Zaledwie **10% najdłuższych sesji** odpowiada za niemal **połowę (45%)** wszystkich par treningowych.

Testowane modele: Wspólne Zadanie i Baseline

Wspólne zadanie

Wszystkie modele rozwiązują **next-item prediction** w sesji e-commerce:

- **Wejście:** historia kliknięć w sesji do momentu t_n-1
- **Wyjście:** przewidzenie produktu klikniętego w t_n
- **Uczenie samonadzorowane:** każdy kolejny klik jest etykietą dla poprzedniego kroku

Wspólny preprocessing i zbiory: **val**, **internal**, **test**.

Baseline: Popularność (POP)

Bez uczenia — globalna lista top-20 najczęściej klikanych produktów z train.

- Ta sama lista rekomendowana dla każdej sesji
- **Metryka:** Recall@20 / Hit Rate@20
- **Punkt odniesienia:** „Czy model w ogóle bije prostą popularność?”

1. GRU4Rec — baseline sekwencyjny

Idea i Architektura

Literatura: Hidasi et al., Session-based Recommendations with Recurrent Neural Networks (2016)

Główna idea: Sesja traktowana jest jako sekwencja ID produktów. Model zapamiętuje kontekst bez jawnego grafu.

Przepływ danych:

Embedding(item) → GRU → Linear → Softmax


Zalety i Ograniczenia

- **Zalety:** Prosty, stabilny, szybki trening i walidacja.
- **Ograniczenia:** Traktuje sesję jako liniową sekwencję — nie modeluje jawnie struktury grafowej ani czasu.

Parametry modelu

Parametr	Wartość
embedding / hidden dim	128
Warstwy GRU	1
Loss	Cross-entropy
Learning rate	0.001
Dropout	0.0

Reprezentacja sesji: uporządkowana lista kliknięć z paddingiem.



2. TAGNN — graf sesji + target attention

Idea i Architektura

Literatura: Wu et al., Target Attentive Graph Neural Networks (SIGIR 2020)

Idea: Sesja jako graf skierowany (węzły=produkty, krawędzie=przejścia). GNN agreguje kontekst, a attention wybiera kluczowe kroki.

Architektura: Embedding → GNN (SR-GNN) → Target Attention → Logits


Zalety i Ograniczenia

- **Zalety:** Modeluje lokalne przejścia (kaskadowość), stabilniejszy niż TGN.
- **Ograniczenia:** Graf tylko w obrębie sesji; brak pamięci temporalnej między zdarzeniami.

Parametry modelu

Parametr	Wartość
hidden_dim	100
Kroki GNN	1
Learning rate	0.001
Weight decay	1e-5
Scheduler	StepLR

Reprezentacja sesji: graf skierowany, macierz sąsiedztwa per sesja.



3. TGN — Temporal Graph Network (model docelowy)

Idea i Architektura

Literatura: Rossi et al., Temporal Graph Networks (2020)

Idea: Sesje i produkty jako węzły w grafie dynamicznym. Każde kliknięcie aktualizuje pamięć; predykcja = link prediction.

Architektura: Zdarzenie → TGN Memory → GNN (temporal attention) → Link decoder (BCE)

Zalety i Ograniczenia

- **Zalety:** Czas ciągły, pamięć temporalna, cechy krawędzi; naturalny model dla logów e-commerce.
- **Ograniczenia:** Kosztowny trening, wymaga replay pamięci; ryzyko przeuczenia na strumieniu.

Specyfikacja modelu

Element	Opis / Wartość
Węzły	Graf dwudzielny
Pamięć	TGNMemory (stan)
Sąsiedztwo	k=10 interakcji
Learning rate	0.0001
Negatywy (train)	1–5 na zdarzenie

Reprezentacja: chronologiczny strumień zdarzeń (events.parquet), a nie graf sesji.

Cechy zdarzeń: Δt , kategoria, price_log, quantity.

Porównanie modeli i Ewaluacja

Cecha	GRU4Rec	TAGNN	TGN
Typ	RNN / sekwencja	GNN na sesji	Graf dyn. + pamięć
Wejście	lista itemów	graf sesji	strumień zdarzeń
Czas	implicit (kolejność)	implicit	explicit (Δt , ms)
Loss	CE	CE	BCE + neg. sampling
Parametry	~setki tys.	~setki tys.	~438k
Stabilność	wysoka	średnia–wysoka	niska (setup)
Val (fit)	full-catalog recall@20	full-catalog recall@20	sampled recall@20

Metryki i Workflow

Metryki: Recall@K, Hit Rate@K (K=5,10,20), MRR@20, NDCG@20

Evaluate (held-out): sampled ranking (target + 99 losowych negatywów)

Workflow: fit (train + val) → evaluate (testy) → W&B logs

Zbiory danych (Splity)

val (15%): subsample czasowy sesji

test_internal (15%): kolejny subsample czasowy

challenge_test: pełny yoochoose-test.dat (cold start)

Finalna ewaluacja - test_internal


test_internal/sampled_recall@5/dataloader_idx_0




test_internal/sampled_recall@20/dataloader_idx_0



test_internal/sampled_recall@10/dataloader_idx_0




test_internal/sampled_recall@1/dataloader_idx_0



test_internal/sampled_ndcg@20/dataloader_idx_0




test_internal/sampled_mrr@20/dataloader_idx_0




Finalna ewaluacja - challenge_test


challenge_test/sampled_recall@5/dataloader_idx_1



challenge_test/sampled_recall@20/dataloader_idx_1



challenge_test/sampled_recall@10/dataloader_idx_1




challenge_test/sampled_recall@1/dataloader_idx_1



challenge_test/sampled_ndcg@20/dataloader_idx_1




challenge_test/sampled_mrr@20/dataloader_idx_1




Finalna ewaluacja - test_internal - najlepsze modele


test_internal/sampled_recall@5/dataloader_idx_0




test_internal/sampled_recall@20/dataloader_idx_0




test_internal/sampled_recall@10/dataloader_idx_0




test_internal/sampled_recall@1/dataloader_idx_0





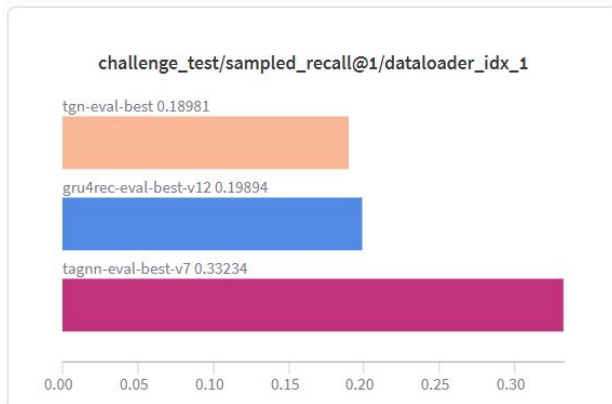
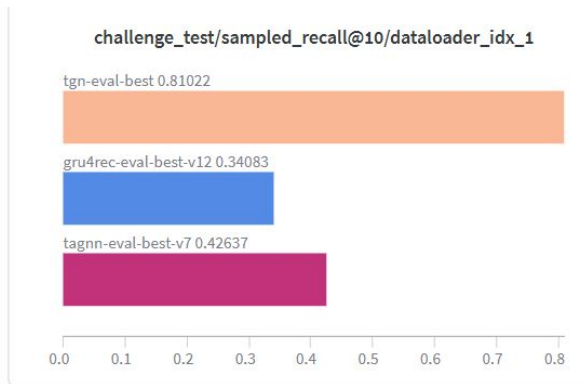
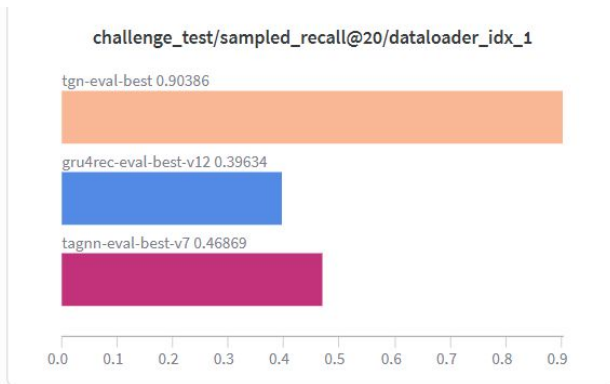
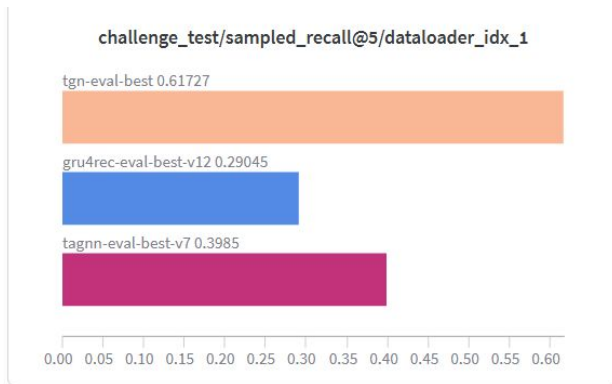
test_internal/sampled_ndcg@20/dataloader_idx_0



test_internal/sampled_mrr@20/dataloader_idx_0



Finalna ewaluacja - challenge_test - najlepsze modele



Dziękujemy za uwagę!

